

[Study 12.도진경] Parallax-Tolerant Unsupervised Deep Image Stitching

- [Title] Parallax-Tolerant Unsupervised Deep Image Stitching
- [Publication] 2023 (ICCV 2023)
- [Reference] [paper](#) | [github](#)

Abstract

- Deep Stitching 기반 robust semantic feature 분석
- large parallax case 대응을 위한 방법 제시
 - Warp: Global Homography와 TPS를 모델링, 중첩 영역은 align / 겹치지 않는 영역의 형태 보존
 - iterative warping: 다른 환경/해상도에서의 generalization 확보
 - seam-driven composition mask 생성을 위한 unsupervised learning.

개요

- Traditional Stitching
 - Feature Extract / Matching
 - : SIFT, Line, Edge, Depth, ...
 - Low Texture, 다양한 영상 활용 어려움.
 - 낮은 추론 속도
- CNN-based Deep Stitching
 - low texture 환경에 robust
 - large parallax 대응 어려움
 - 학습 데이터 이외의 환경/해상도에서 낮은 성능
- Proposed
 - Global Homography와 TPS 추정

: 전체적으로는 이만큼(Homography), 세부적으로는 요만큼(TPS) 움직인다.

: 전체적인 틀(Global)과 세부적인 비틀림(Local)을 동시에 고려하기 때문에, 한 대상에만 맞췄을 때 발생하는 오차(예: 배경은 맞는데 앞쪽 물체는 어긋나는 현상)를 줄일 수 있다.

- Seam composition 시 ghost 현상 개선

Method




Figure 2: An overview of the proposed parallax-tolerant unsupervised stitching network. Our framework consists of two stages: warp and composition. The first stage predicts a robust and flexible warp to align images with shape preservation. The second stage composites the seamless stitched image by generating composition masks corresponding to warped images.

$$(S = M_{cr} \times I_{wr} + M_{ct} \times I_{wt})$$

Unsupervised Warp

· Warp Parameterization

1. Homography: 8개 자유도(translation|rotation|scale|shear 등) 로 표현 -> DLT 사용, 3x3 행렬로 변환

*DLT: 대응되는 4개 pt 기반 Homography 계산

2. TPS

: NxV 개의 point 지정, 각 point의 이동량

$$(\Delta p)$$

을 예측, 최종 warped 좌표

$$P'$$

추정

: Parameterization) TPS 수식 내 변환 계수(C,M,W) 계산

: Warping) C,M,W를 사용해서 모든 픽셀이 어느 위치로 이동하는지 계산.

$$\left(p' = \mathcal{T}(p) = C + Mp + \sum_{i=1}^N w_i O(\|p - p_i\|_2) \right)$$

- M (Affine Part): 이미지의 선형 변환 (회전/크기)
- C (Translation): 평행 이동
- W (Non-linear Part): 비선형 왜곡 계수, point 주변을 늘리거나 맞춤.

· Pipeline of Warp

ResNet50 사용 → feature 계산

1/16 feature map으로 point 이동량 계산 → 초기 homography 계산

1/8 feature map으로 세부 이동량 계산 → TPS 계산

1. ResNet50을 backbone으로 사용

: semantic feature 추출

2. 1/16 feature 기반 Contextual Correlation 계산

: Homography 추정에 어떤 영역에 어느 정도의 가중치를 둘 지 판단.

:

$$F_{1/16}$$

→ Regression Network → 4-pt parameterization

3. 1/8 feature 기반 Coarse-to-Fine Refinement

- 1/16 에서 예측된 호모그래피(Global Warp)를 tgt 1/8 feature에 적용
- ref 1/8 feature가 warped tgt 1/8 feature의 어느 point로 매칭되는지 계산, 포인트의 미세 조정값 출력 → TPS 계산

· Warp 최적화

content alignment and shape preservation

$$(\mathcal{L}^w = \mathcal{L}_{\text{alignment}}^w + \omega \mathcal{L}_{\text{distortion}}^w)$$

Alignment Loss

$$\mathcal{L}_{\text{alignment}}^w = \lambda \|I_r \cdot \varphi(\mathbf{1}, \mathcal{H}) - \varphi(I_t, \mathcal{H})\|_1 + \lambda \|I_t \cdot \varphi(\mathbf{1}, \mathcal{H}^{-1}) - \varphi(I_r, \mathcal{H}^{-1})\|_1 + \|I_r \cdot \varphi(\mathbf{1}, TPS) - \varphi(I_t, TPS)\|_1,$$

- $H, \mathcal{H}^{-1}$
: 초기 Homography 기반 정렬 시 오차를 양방향으로 줄임.
- TPS
: TPS 정렬 시 오차 줄임.

Distortion Loss




Figure 4. Mesh shape-preserving constraint.

Deep Rectangling for Image Stitching: A Learning Baseline (CVPR 2022)

- Inter-grid Constraint, ℓ_{inter}
 - 목적: 겹치지 않는 영역의 모양 유지
 - 방법: 연속된 두 선분($\vec{e}_{s1}, \vec{e}_{s2}$)이 일직선(180°)을 유지
 - Cosine Similarity: 두 선분 사이의 각도가 커지면(내적이 1에서 멀어지면) penalty
 - 핵심 포인트 ($S_{s1,s2}$): 미중첩 영역에만 적용. 겹치는 영역에서는 정렬을 위해 선이 휘어질 수 있어야 하기 때문
- Intra-grid Constraint, ℓ_{intra}
 - 목적: mesh가 너무 과하게 늘어나거나 줄어드는 **Projective Distortion** 방지
 - 방법: 격자의 가로/세로 선분($\vec{e}$)의 길이 비교
 - *ReLU*: 선분의 길이가 임계값(이미지 크기를 격자 수로 나눈 평균 길이)을 넘어서면 Penalty
 - : 격자 모양이 급격하게 커지는 것을 막아 이미지의 해상도 깨짐 방지

Unsupervised Seamless Composition

· Motivation

- 기존 방식의 한계 극복
 - Seam Cutting: pixel의 밝기 차이에 의존, 무거운 연산
 - Deep Learning 기반, 0~1 사이의 실수 값을 갖는 Soft Mask를 추정 (학습 가능한 형태)

· Pipeline of Composition

- UNet 구조 사용
1. Shared Weights Encoder
: warped Image(ref, tgt)에서 semantic feature 추출
 2. Skip Connection
: 두 feature의 residual을 계산, decoder에 적용 - 두 이미지의 차이를 학습
 3. Mask Prediction
: Sigmoid 함수를 사용, 0~1 사이의 값을 갖는 mask 생성

· Optimization of Composition

- boundary term and a smoothness term
1. boundary term
 - : 경계의 시작-끝 지점을 지정
 - : 마스크의 경계가 갑자기 끊기지 않고 부드러워야 함.
 - : 두 이미지가 겹치는 영역의 맨 끝 경계선(M_{br}, M_{bt})에서, 합성 이미지(S)가 각각 원래 이미지(I_{wr}, I_{wt})와 똑같아야 한다.
 2. Smoothness Loss
 - seam 이 지나가는 경로를 추정
 - Smoothness on Difference Map (ℓ_D)
 - : 두 이미지의 픽셀 값 차이가 큰 곳(D)에서는 마스크의 급격한 변화 X
 - : 두 이미지가 서로 다르게 생긴 곳은 경계로 정하지 않는다.
 - Smoothness on Stitched Map (ℓ_S)
 - : 최종 결과물(S)에서 seam 주변 픽셀들이 부드럽게 이어지도록 한다.

Iterative Warp Adaption

$$\mathcal{L}_{\text{adaption}}^w = \|I_r \cdot \varphi(1, \mathcal{TPS}) - \varphi(I_t, \mathcal{TPS})\|_1$$

- 비학습 환경/데이터셋에서도 적용 가능하도록 self-optimization
 - : TPS 조정을 위한 학습만 반복 진행
 - : 학습 횟수가 늘어날수록 artifact 감소

Experiments




Figure 3: We demonstrate the process of iterative warp adaption on “railtrack” dataset [50] (cross-dataset and cross-resolution).

- Fig 3. Iterative 반복될수록 artifact 제거, 오차 줄어듦.

Table 1: Quantitative comparison of warp on UDIS-D dataset [41]. The best is marked in red and the second best is in blue.

	PSNR $\uparrow$				SSIM $\uparrow$			
	Easy	Moderate	Hard	Average	Easy	Moderate	Hard	Average
$I_{3\times3}$	15.87	12.76	10.68	12.86	0.530	0.286	0.146	0.303
SIFT[38]+RANSAC[12]	28.75	24.08	18.55	23.27	0.916	0.833	0.636	0.779
APAP[50]	27.96	24.39	20.21	23.79	0.901	0.837	0.682	0.794
ELA[28]	29.36	25.10	19.19	24.01	0.917	0.855	0.691	0.808
SPW[32]	26.98	22.67	16.77	21.60	0.880	0.758	0.490	0.687
LPC[19]	26.94	22.63	19.31	22.59	0.878	0.764	0.610	0.736
UDIS's warp[41]	25.16	20.96	18.36	21.17	0.834	0.669	0.495	0.648
Our warp	30.19	25.84	21.57	25.43	0.933	0.875	0.739	0.838




Figure 4: Qualitative comparison of warp on UDIS-D dataset [41]. We zoom in on a near region and a far region to show the alignment performance. For clarity, we show the inputs and more comparative results in the supplementary material.

- Fig 4. 깊이차가 발생하는 대상의 alignment 및 seam 성능 비교



Figure 5: Qualitative comparison of warp on “boardingBridge” dataset [28] with a resolution of 1440×2160 for inputs. The yellow and red arrows highlight projective and structural distortions.

- Fig 5. 타 데이터셋에 대한 성능 비교

Table 2: Comparison of warp on elapsed time (s). 1: tested with Intel i7-9750H 2.60GHz CPU; 2: tested with NVIDIA RTX 3090Ti GPU.

Dataset	Railtrack [50]	Fence [34]	Carpark [13]
Resolution	1500×2000	1088×816	490×653
APAP [50] ¹	20.921	4.427	2.005
ELA [28] ¹	18.982	4.739	2.179
SPW [32] ¹	227.762	4.787	6.583
LPC [19] ¹	2805.3	9.115	40.443
Our warp ¹	12.073	5.025	3.486
Our warp ²	0.731	0.210	0.117

Table 3: Comparison of composition on elapsed time (s). 1: tested with Intel i7-9750H 2.60GHz CPU; 2: tested with NVIDIA RTX 3090Ti GPU.

Dataset	Railtrack [50]	Fence [34]	Carpark [13]
Resolution (after warping)	1831×3193	1298×1320	718×1186
Seam cutting [30] ¹	46.657	4.058	0.873
Reconstruction [41] ¹	304.963	80.837	10.734
Our composition ¹	22.778	6.666	3.286
Our composition ²	0.532	0.143	0.071

- Table 2. GPU 가속 사용 가능, 비선형 warping 발생 시 traditional method의 속도 느려짐.




Figure 7: Ablation studies on our warp and composition. Top: the red and yellow arrows highlight the structural and projective distortions, respectively. Bottom: the rectangles indicate the discontinuous regions.

- Ablation studies on our warp and composition

○

ℓ_{inter}

(그리드 간 제약): 없으면 겹치지 않는 배경 영역의 구조 변형됨.

◦ ℓ_{intra}

(그리드 내부 제약): 없으면 심한 왜곡(Projective Distortion) 발생.